

Capitolo 1

Introduzione

1.1 Contesto

Oramai alle catene di produzione è richiesta una grande flessibilità e adattabilità. Da questo nasce l'industria 4.0 in cui si fa utilizzo di macchine automatiche, le quali garantiscono alti livelli di precisione, affidabilità e velocità; tuttavia mancano ancora di caratteristiche essenziali come adattabilità o intelligenza in modo da essere compatibile con l'idea di smart manufacturing. Una delle tecnologie abilitanti per questo settore è diventata la Human-Robot Collaboration.

1.2 Human-Robotic Collaborative

Con *Human-Robotic Collaborative* (HRC) si riferisce a scenari applicativi in cui un robot, generalmente collaborativo, e un umano occupano lo stesso spazio di lavoro e interagiscono per eseguire compiti con un obiettivo comune.

Un *cobot* (derivante da " collaborative robot ") è un robot concepito per interagire fisicamente con l'uomo in uno spazio di lavoro. In contrasto rispetto alla maggior parte dei robot industriali adottati fino al 2008, i quali erano progettati per operare in maniera autonoma o con una guida limitata e protetti da barriere. Uno dei primi modelli è l'UR3 (Universal Robots) mostrato in *Figura 1.1*.

L'obiettivo è quello di combinare:

- le impressionanti capacità fisiche dei robot;
- le capacità cognitive degli umani necessarie per risolvere le incertezze e le variabilità dovute alla mass customization.



Figura 1.1: Universal Robots 3

Una delle principali sfide della HRC è la complessità della programmazione dei robot tradizionali, dato che richiede competenze specialistiche e può essere rigida rispetto ai cambiamenti frequenti nei processi produttivi. Per ridurre tale complessità vengono utilizzate diverse tecniche di apprendimento automatico, sia supervisionate che non, per migliorare l'interazione tra esseri umani e robot.

Si richiedono approcci di programmazione più rapidi ed efficienti per fare in modo che il robot possa lavorare rapidamente a nuovi task. L'approccio che si utilizza per raggiungere questo obiettivo è quello della Learning from Demonstration.

1.3 Learning from Demonstration

Con *Learning from Demonstration* (LfD) si intende una tecnica di programmazione dei robot basata su un insieme di algoritmi di apprendimento, ispirata al modo in cui gli esseri umani imitano i comportamenti per imparare e acquisire nuove abilità. Nasce per dare la possibilità all'utente finale di personalizzare e adattare il cobot alle proprie necessità senza richiedere skill o conoscenze di programmazione. Il robot impara il task a partire da una dimostrazione del comportamento desiderato.

Nel successivo capitolo facciamo una panoramica di tutto quello che è lo stato attuale di ricerca rispetto a questo argomento.

Capitolo 2

Learning from Demonstration

Il principale problema nella robotica consiste nel trovare la corretta mappatura tra lo stato del mondo e l'azione da intraprendere, ovvero come tradurre le percezioni del robot in decisioni operative efficaci. Questo mapping, noto anche come *policy*, è cruciale.

Le problematiche nella definizione delle policies derivano dalla complessità dei modelli necessari per rappresentare accuratamente l'ambiente e il sistema robotico. Inoltre, le semplificazioni e le linearizzazioni spesso necessarie possono causare un degrado delle performance, rendendo difficile ottenere un comportamento ottimale. Queste difficoltà hanno portato all'adozione di tecniche di machine learning per la definizione delle policies. Tra queste, una delle tecniche più rilevanti è la LfD, che si basa sull'apprendimento tramite dimostrazioni delle azioni da eseguire.

2.1 Formulazione del problema

La LfD può essere vista come un sottoinsieme del *Supervised Learning*; diamone una definizione.

Supervised learning: paradigma di machine learning nel quale un agente è allenato su dati etichettati affinché riesca ad approssimare la funzione che ha prodotto i dati.

La LfD è quindi un caso di Supervised Learning, tipicamente utilizzato nel campo della robotica, nel quale i dati etichettati sono forniti attraverso dimostrazioni d'esempio del task d'interesse, eseguite da un soggetto denominato *teacher* o *demonstrator*. Il soggetto

che impara dal teacher è detto *learner*. Sono numerose le formulazioni matematiche fornite, ma in questo elaborato faremo riferimento a quella fornita in [1]. Denotiamo:

- S , insieme degli stati
- A , insieme delle azioni (sia di movimento che più complesse)
- $T(s'|s, a) : S \times A \times S \mapsto [0, 1]$, funzione di mapping probabilistica tra S ed A
- Z insieme degli stati osservabili
- $M : S \mapsto Z$, funzione di mapping tra stati e stati osservabili
- $\pi : Z \mapsto A$, policy che seleziona le azioni sulla base delle osservazioni dello stato
- D , insieme delle dimostrazioni
- $d_j = (z_j^i, a_j^i)$, dimostrazione j -esima, $d_j \in D, z_j^i \in Z, a_j^i \in A$

Nei sistemi reali l'insieme degli stati S non è completamente osservabile, pertanto il learner riesce ad osservarne solamente un sottoinsieme $Z \subseteq S$. L'insieme delle dimostrazioni D viene fornito al learner, che deve riuscire a derivare una policy. Nell'elaborato ci riferiamo a $Z \times A$ come *spazio di rappresentazione*.

Cerchiamo di dare una definizione sulla base delle nozioni appena introdotte.

Learning from Demonstration: paradigma di machine learning nel quale un agente, detto learner, è allenato su dati forniti tramite dimostrazioni di task, eseguite da un soggetto denominato teacher o demonstrator.

Nella definizione non facciamo riferimento alla inferenza di una policy poichè, come vedremo nelle prossime sezioni, le tecniche di inferenza utilizzate sono diverse, e solamente quelle basate sul mapping producono policy. Altre tipologie producono funzioni di costo o piani d'azione.

2.2 LfD Workflow

Il processo di LfD può essere visto come composto da 5 passi:

1. **Demonstrator Selection:** si decide il soggetto che esegue la dimostrazione.
2. **Data Acquisition:** si decide la tecnica di dimostrazione da utilizzare, e la si mette in atto per costruire il dataset.

3. **Data Modeling:** si scelgono ed utilizzano tecniche per apprendere una serie di regole (policy) per mappare le azioni dimostrate agli stati visti e, in ultima analisi, cerca di dedurre quale serie di azioni può essere applicata agli stati non osservati durante le dimostrazioni.
4. **Skill/Task Execution** si valuta la conoscenza acquisita dal robot.
5. **Learning Refinement:** step opzionale in cui si migliora incrementalmente la conoscenza del learner.

2.3 Demonstrator Selection

La prima fase da affrontare è quella della selezione del demonstrator, cioè chi è il soggetto che compie la dimostrazione. Questa fase comprende anche la selezione di chi controlla il demonstrator, poiché la dimostrazione potrebbe essere effettuata manipolando il robot stesso o osservando un secondo robot. Si tratta di una scelta che dipende da diversi fattori, tra cui il form factor del robot, la possibilità di poterlo manovrare in loco e risorse a disposizione.

Possiamo differenziare immediatamente 3 casistiche:

Teacher	Controllore	Descrizione
Operatore umano	Operatore umano	Un operatore umano esegue il task da ripetere.
Robot	Robot	Un robot capace di effettuare autonomamente il task lo esegue.
Robot	Umano	Un robot controllato da un umano esegue il task da ripetere.

Tabella 2.1: Scenari demonstrator-controllore

La scelta del demonstrator è importante poiché la similarità tra spazio degli stati S e spazio delle azioni A è importante per la scelta dell'algoritmo di inferenza.

2.4 Data Acquisition

Nella fase di data acquisition la dimostrazione viene effettuata e vengono raccolti i dati necessari alla successiva inferenza di policy e simili. È cruciale in questa fase la scelta della tecnica da utilizzare per effettuare la dimostrazione, che è strettamente correlata alla fase precedente. In letteratura queste tecniche sono classificate in numerosi modi.

Riteniamo la categorizzazione presente in [2] la più completa dal punto di vista di tecniche rappresentate. Al contempo consideriamo la categorizzazione presente in [1]

significativa dal punto di vista semantico, data l'interessante divisione in *Dimostrazioni* ed *Imitazioni*. Presentiamo pertanto in questo testo una integrazione delle due rappresentazioni, il cui schema è mostrato in figura 2.1. In questa sezione descriviamo e motiviamo la differenziazione applicata, lasciando al capitolo 3




Figura 2.1: Tecniche per la dimostrazione

2.4.1 Corrispondenza

Per poter descrivere la differenza tra Dimostrazioni ed Imitazioni dobbiamo innanzitutto trattare il tema della corrispondenza, ovvero come mappare i dati ottenuti tramite le dimostrazioni in uno spazio di rappresentazione (stati ed azioni) consono per il learner. In [1] questa corrispondenza è suddivisa in due funzioni di mapping:

- **Record Mapping** $\mathbf{g_R(z, a)}$: mappa lo spazio di rappresentazione del teacher nello spazio di rappresentazione raccolto nel dataset in fase di dimostrazione.
- **Embodiment Mapping** $\mathbf{g_E(z, a)}$: mappa lo spazio di rappresentazione raccolto nel dataset in fase di dimostrazione nello spazio di rappresentazione del learner.

In figura 2.2 è possibile vedere uno schema che mostra come vengono applicati i due mapping.




Figura 2.2: Funzioni di mapping

Sulla base del valore dell'Embodiment Mapping $g_E(z, a)$ possiamo definire:

- **Dimostrazioni pure:** parliamo di dimostrazioni pure quando $\mathbf{g_E(z, a)} = \mathbf{I(z, a)}$, o in altre parole, quando non viene effettuato un Embodiment Mapping. Questo avviene quando la dimostrazione è effettuata direttamente sul learner.
- **Imitazioni:** parliamo di imitazioni quando $\mathbf{g_E(z, a)} \neq \mathbf{I(z, a)}$, ovvero quando è necessario effettuare l'Embodiment Mapping. Questo avviene quando la dimostrazione è effettuata su un soggetto diverso dal learner.

Questa differenziazione è la più rilevante, poiché diversi lavori si concentrano unicamente su una delle due categorie. Piattaforme tipiche per l'imitazione sono umani o robot simili al learner.

A questo punto è possibile suddividere ulteriormente le dimostrazioni pure ed imitazioni in base al Record Mapping.

Dividiamo le tecniche dimostrazione pura in:

- **Physical Guidance:** il robot è controllato dal teacher che ne definisce i movimenti ($\mathbf{g_R(z, a)} = \mathbf{I(z, a)}$).
- **Interactive Guidance:** durante la dimostrazione il robot si muove con feedback da parte dell'operatore. ($\mathbf{g_R(z, a)} \neq \mathbf{I(z, a)}$).

Dividiamo le tecniche di imitazione (dette anche di *Observable Guidance*) in:

- **Sensors on Teacher:** durante la dimostrazione i sensori sono posti direttamente sul teacher che ne rilevano stati ed azioni ($\mathbf{g_R(z, a)} = \mathbf{I(z, a)}$).
- **External Observation:** durante la dimostrazione si utilizzano sensori esterni al teacher per raccogliere dati sull'esecuzione ($\mathbf{g_R(z, a)} \neq \mathbf{I(z, a)}$).

Le categorizzazione appena definite sono evidenziate in figura 2.2.

Nelle prossime sezioni entreremo nel merito di queste tecniche evidenziandone caratteristiche e criticità.

	Demonstration $\mathbf{g_E(z, a) = I(z, a)}$	Imitation $\mathbf{g_E(z, a) \neq I(z, a)}$
$\mathbf{g_R(z, a) = I(z, a)}$	Physical Guidance	Sensors on Teacher
$\mathbf{g_R(z, a) \neq I(z, a)}$	Interactive Guidance	External Observation

Tabella 2.2: Categorizzazione basata sulle funzioni di mapping

2.4.2 Physical Guidance

Le tecniche di Physical Guidance sono tecniche di dimostrazione pura nella quale la dimostrazione viene effettuata nello spazio di rappresentazione del robot controllandolo manualmente manovrandolo direttamente o tramite delle interfacce. Un requisito importante è quindi che il robot sia manovrabile, ed all'aumentare dei gradi di libertà di movimento di movimento questo requisito viene meno. Un'altra criticità è la mancanza di precisione introdotta dal fattore umano, che potrebbe essere necessario mitigare tramite manipolazione dei dati.

Rientriamo nel caso in cui $g_E(z, a) = I(z, a)$ e $g_R(z, a) = I(z, a)$, si tratta quindi del caso con il trasferimento di informazioni più diretto.

Esempi di tecniche di Physical Guidance sono:

- **Kinesthetic teaching:** l'operatore muove fisicamente il robot attraverso i movimenti desiderati, che sono quindi registrati tramite sensori integrati. Oltre alla manovrabilità e alla presenza fisica di un operatore non sono presenti requisiti particolarmente limitanti, ma la tecnica dipende fortemente dalla capacità dell'operatore umano di muovere correttamente il robot. È una tecnica utilizzata particolarmente con robot manipolatori, per via del loro semplice form factor.
- **Teleoperazione:** l'operatore utilizza una interfaccia esterna per manipolare il robot, come joystick o sistemi di AR/VR. Questo implica quindi uno sforzo implementativo non indifferente per realizzare interfacce, l'allenamento di operatori per l'utilizzo di quest'ultimo, e la possibilità di reperire l'hardware necessario. D'altra parte questo permette la manipolazione di sistemi più complessi, e un'integrazione maggiore con sistemi di simulazione. Un altro aspetto positivo è che non è più necessaria la presenza umana, abilitando quindi applicazioni remote

della tecnica, ove non sarebbe possibile altrimenti (e.g. [3]), e permettendo anche dimostrazioni in larga scala.

2.4.3 Interactive Guidance

Le tecniche di Interactive Guidance sono tecniche di dimostrazione pura dove il robot learner è libero di muoversi, interagendo tramite feedback o imitando in real-time i movimenti del teacher.

Si ha $g_E(z, a) = I(z, a)$, ma in questo caso $g_R(z, a) \neq I(z, a)$, poiché i dati dell'interazione del teacher non sono rappresentati nel dataset, dove sono presenti solamente stati ed azioni del robot learner.

Distinguiamo due tecniche:

- **Shadowing:** tecnica nella quale il robot imita i movimenti di dimostrazione del teacher, registrando i propri movimenti. Si tratta di una dimostrazione poiché il dataset non contiene dati sul teacher, bensì sui movimenti eseguiti dal robot. La traduzione da movimenti del teacher a quelli del robot richiede l'utilizzo di un algoritmo, quindi uno sforzo implementativo e computazionale.
- **Reactive Guidance:** durante la dimostrazione il robot si muove esplorando i set di azioni predefiniti, ricevendo feedback da parte dell'operatore sulla correttezza delle azioni eseguite e/o che azioni eseguire. Sono utilizzati metodi come il Reinforcement Learning e l'Active Learning.

2.4.4 Sensors on Teacher

Sensors on teacher è un approccio all'Imitation learning che prevede l'utilizzo di sensori presenti sul demonstrator, registrandone stato ed azioni. In questo caso $g_R(z, a) = I(z, a)$ dato che i dati raccolti coincidono con stato ed azioni del teacher, ma $g_E(z, a) \neq I(z, a)$ poiché il dataset necessita di essere mappato nello spazio di rappresentazione del learner.

2.4.5 External Observation

L'imitazione tramite External Observation prevede la raccolta di dati sulla dimostrazione tramite sensori non posizionati sul teacher. In questo approccio abbiamo che $g_E(z, a) \neq I(z, a)$ e $g_R(z, a) \neq I(z, a)$, in quanto i dati non sono raccolti direttamente dal teacher, e necessitano inoltre di essere mappati nello spazio di rappresentazione del learner.

2.4.6 Multimodal Guidance

L'approccio Multimodal Guidance non è altro che l'utilizzo di una combinazione dei metodi precedentemente descritti. Questa tecnica può essere utilizzata per diminuire l'incertezza o per riuscire ad insegnare al learner task complessi, utilizzando la tecnica più adeguata al task da apprendere. Un approccio misto implica anche un aumento di complessità in fase di data fusion, data la maggiore eterogeneità dei data da integrare.

2.5 Policy Derivation

Una volta definiti, sulla base dei requisiti, sia il teacher che la tecnica di dimostrazione da utilizzare, e dopo aver realizzato le dimostrazioni vere e proprie in base alla tecnica scelta, il dataset observation-action $D = \{(z', a')\}$ così ottenuto è il punto di partenza per la fase di derivazione della policy.

La LfD ha visto lo sviluppo di tre approcci fondamentali, mostrati in *Figura 2.3*, per derivare le policies. Ne diamo una breve descrizione per poi approfondirli singolarmente:

- *Mapping Function*: i dati raccolti in fase di dimostrazioni sono utilizzati direttamente per determinare la funzione nascosta che mappa le osservazioni del robot alle azioni.
- *System model*: i dati di dimostrazione sono utilizzati per determinare il modello dinamico del mondo e una funzione di reward che verranno utilizzate per derivare le policies.
- *Plans*: i dati sono utilizzati per imparare delle regole che associano un insieme di precondizioni e post condizioni ad un azione. A partire da queste informazioni si pianifica una sequenza di azioni.




Figura 2.3: Panoramica delle tecniche core

La LfD può essere applicata ad una grande varietà di livelli di controllo dell'azione del robot, in base alla formulazione del problema. Le tipologie di azioni che possiamo derivare dalle tecniche sopra citate possono essere classificate in:

- *Low-Level motion*: un movimento primitivo che consente al robot di muoversi liberamente all'interno dell'ambiente. Dunque consiste nell'insegnare al robot singoli movimenti a partire dalla dimostrazione.

- *High-Level problem solving*: la risoluzione di un task, definito come un insieme di movimenti primitivi che permettono di risolvere uno specifico problema industriale.

2.5.1 Mapping Function

Questo approccio al policy learning calcola la funzione che approssima il mapping stato-azione per un dato comportamento dimostrato. Dunque cerca di riprodurre la policy applicata dal teacher che risulta sconosciuta, e di generalizzare il più possibile sul set di esempi a disposizione, in modo che la soluzione sia valida anche per stati simili ma che non si sono incontrati durante la dimostrazione.

In generale le tecniche di mapping rientrano in due categorie sulla base della natura dell'output predetto, infatti si parla di:

- *Classificazione*: quando gli algoritmi producono output che sono discreti.
- *Regressione*: quando gli algoritmi producono output che sono continui.

Classificazione

Nel contesto del policy learning, abbiamo che l'input del classificatore sono gli stati del robot mentre le classi discrete che produce in output sono le azioni del robot.

Tra i principali lavori proposti abbiamo utilizzo di tecniche di classificazione "classiche" (SVM, DT, Random Forest, ...) ma anche diverse come Gaussian Mixture Models (GMMs).

Regressione

Questi approcci mappano gli stati dimostrati allo spazio continuo delle classificazioni. La tipologia di input e output è analoga a quella della classificazione, Tuttavia questa tipologia di approccio si applica solamente ai Low-Level motions.

2.5.2 System Model

Questo approccio fa uso di un modello di transizione di stato del mondo $T(s'|s, a)$, determinato a partire dal dataset delle dimostrazioni e da eventuali osservazioni del robot, al partire dal quale si derivano le policy, Questo approccio è tipicamente formulato con la struttura del *Reinforcement Learning* (RL). La quale prevede:

- *Agente*: colui che prenderà decisioni all'interno dell'ambiente.

- *Ambiente*: contesto in cui l'agente opera, risponde all'azione dell'agente aggiornando il suo stato e fornendo una ricompensa.
- *Stato*: rappresenta la situazione attuale dell'ambiente, che l'agente osserva per decidere quale azione intraprendere.
- *Azione*: scelta effettuata dall'agente basata sull'osservazione dello stato corrente. L'azione modificherà lo stato dell'ambiente.
- *Reward*: rappresenta il feedback fornito dall'ambiente dopo che l'agente ha eseguito un'azione. Quantifica quanto è buona o cattiva l'azione in base agli obiettivi che l'agente deve raggiungere. Il fine dell'agente è massimizzare il totale delle ricompense cumulative nel tempo.
- *Policy*: è la strategia che l'agente segue per decidere quale azione intraprendere in ogni stato. L'obiettivo dell'agente nel Reinforcement Learning è apprendere una policy ottimale, che massimizza le ricompense attese.
- *Funzione di Valore*: permette di valutare quanto è vantaggioso trovarsi in un certo stato o eseguire una certa azione in uno stato, in termini di ricompense future attese. Grazie a questa valutazione, l'agente può raffinare la scelta delle azioni da intraprendere per massimizzare la somma delle ricompense nel lungo termine.




Figura 2.4: Schema Reinforcement Learning

L'agente esegue un'osservazione dello stato dell'ambiente e tramite la policy decide quale azione intraprendere. L'azione eseguita nell'ambiente, ne può causare un cambiamento di stato. L'ambiente restituisce una ricompensa r all'agente, che riflette

l'utilità dell'azione appena eseguita. Questa insieme al nuovo stato s' sono utilizzati per aggiornare la policy tramite la funzione di valore.

Gli approcci RL tipicamente non generalizzano gli stati, dunque occorre fornire una dimostrazione per ogni stato discreto. Definire la reward function in modo tale che catturi l'esecuzione desiderata del task non è così semplice.

L'implementazione LfD dei metodi system model si può classificare sul come si è derivata la Reward function:

- *Engineered Reward Function*: ovvero definita manualmente da parte di un utente. Le dimostrazioni sono viste come soluzione ottima e sono utilizzate per fare inferenza sulla sottostante funzione di costo
- *Learned Reward Function*: in questo caso la funzione è imparata dal dataset di dimostrazione. L' *Inverse Reinforcement Learning* è un esempio di come derivare la funzione dal dataset.

2.5.3 Plans

In questo approccio il comportamento desiderato del robot è rappresentato mediante un piano. Seguendo questo approccio la policy è definita come una sequenza di azioni che partono da uno stato iniziale ed arrivano allo stato finale desiderato. Ogni azione è definita in termini di:

- *Pre-condizioni*: stato che deve verificarsi prima che l'azione possa essere eseguita.
- *Post-condizioni*: stato risultante in seguito all'esecuzione dell'azione.

Rispetto agli altri approcci LfD nelle tecniche di planning non si fa affidamento solamente sulla dimostrazioni observation-action ma anche su informazioni aggiuntive (annotazioni o intenti) sempre provenienti dal teacher.

2.6 Skill/Task Execution

Arrivati a questo punto, il learner è capace di eseguire autonomamente delle azioni, ma è necessario valutare la qualità dell'apprendimento. Idealmente dovrebbe essere capace di adattarsi anche a variazioni rispetto all'ambiente di dimostrazione, eseguendo in modo autonomo task simili a quelli dimostrati, quindi possedendo capacità di generalizzazione.

Tuttavia questo non è sempre possibile.

Per come è definita la LfD, le performance del learner sono limitate dalla quantità di informazioni fornita dal dataset di dimostrazione. Le cause di performance sotto le aspettative sono:

- *Undemonstrated state*: la presenza di un dataset di training limitato, limita anche le policies che la LfD è in grado di derivare. Nella maggior parte dei domini non è possibile mostrare l'azione corretta per ogni possibile stato, allora ci poniamo la domanda:

Cosa succede quando un robot deve compiere un'azione in uno stato che non gli è stato dimostrato?

I metodi che hanno a che fare con gli stati non dimostrati sono due:

1. *Generalizzazione*: si generalizza sui dati che si hanno a disposizione.
 2. *Acquisizione*: si eseguono nuove dimostrazioni sui nuovi stati incontrati.
- *Poor quality data*: la qualità delle dimostrazioni impatta molto le policies che andremo a derivare. Le dimostrazioni del teacher potrebbero essere ambigue o sub-ottimali. Per risolvere queste problematiche:
1. Si rimuovono le dimostrazioni sub-ottimali del teacher.
 2. Si utilizzano approcci di learning from experience quindi RL.

2.7 Learning Refinement

La fase del learning refinement non è sempre presente nel workflow della LfD. Questo accade perchè tipicamente la fase di acquisizione (Data acquisition) e la fase di modellazione (Data Modeling) sono indipendenti. Apprendere task diversi, o più semplicemente modificare dei parametri, prevede di effettuare nuovamente la dimostrazione, attività tipicamente eseguita offline. Questo implica un dispendio di tempo non trascurabile. Inoltre, per ottenere risultati validi, molte tecniche di modellazione richiedono dataset di dimensione tale da rendere non realistico che queste avvengano in tempi ragionevoli.

Un approccio per la risoluzione di questo problema è chiamato Incremental Learning (IL), ovvero l'utilizzo di tecniche che permettano l'apprendimento tramite nuove dimostrazioni preservando le capacità precedentemente apprese.

Nella LfD si può quindi raccogliere una quantità di dimostrazioni tale che il learner abbia una capacità iniziale sufficiente allo svolgimento del task, seppur non in maniera ottimale, per poi applicare l'Incremental Learning e migliorare le performance nel tempo, tramite nuove dimostrazioni eseguite on-line.

2.8 Teaching-Learning-Collaboration

In questa sezione esploriamo brevemente il mondo della Teaching-Learning-Collaboration (TLC) [4], che si può interpretare come caso particolare di Learning from Demonstration nel quale operatore umano e robot collaborano, e quest'ultimo impara osservando il comportamento dell'operatore.

I vantaggi apportati da questo approccio sono diversi. Si tratta di un'ottima soluzione per portare a termini task ibridi complessi, sfruttando i punti di forza delle due diverse parti. I robot possono lavorare senza affaticarsi garantendo un'alta produttività, sopportando carichi maggiori rispetto a quelli dell'operatore, che invece contribuisce manovrando componenti che richiedono particolare accuratezza, e con la capacità di adattarsi velocemente a nuovi task. Quest'ultimo punto in particolare risulta essere di grande importanza, poiché il settore manifatturiero odierno prevede cambiamenti rapidi nelle caratteristiche dei prodotti, che risultano essere inoltre personalizzabili. L'approccio classico prevederebbe di fermare la macchina per effettuare nuovamente il training, prevedendo perciò significativi tempi morti e la presenza di esperti informatici, ma questo non è compatibile con i rapidi cambiamenti dell'industria. Con un approccio TLC questo non è necessario, poiché un operatore senza particolare expertise è capace di aggiornare le capacità del robot attraverso le dimostrazioni, permettendogli quindi di operare autonomamente.

Si tratta di uno shift rilevante rispetto all'approccio classico *robot-in-a-cage*. Gli approcci alle tecniche di dimostrazione e di inferenza delle policy utilizzati nel TLC sono variazioni di quelle descritte nelle precedenti sezioni. In figura 2.5 mostriamo il workflow del Teaching-Learning-Collaboration.




Figura 2.5: TLC Workflow

Capitolo 3

Data acquisition workflow

L'obiettivo di questo capitolo è riuscire a fornire un riferimento su come affrontare la fase di Data Acquisition nella Learning from Demonstration. Diamo quindi una descrizione delle tecniche coinvolte delineando, per ognuna di esse, processo operativo, criticità e riferimenti in letteratura.

3.1 Kinaesthetic Teaching

3.1.1 Descrizione

Il kinaesthetic teaching, o apprendimento cinestetico, è una tecnica per effettuare dimostrazioni per la LfD, nella quale un operatore opera con le proprie mani il robot learner, manovrandolo e muovendolo lungo la traiettoria desiderata, che dovrà poi essere appresa e ripetuta autonomamente. Gli stati attraverso cui passa il learner sono registrati, insieme alle informazioni temporali, dai sensori interni al learner, e sono poi utilizzati per inferire la traiettoria effettiva del task da ripetere.

3.1.2 Requisiti

La tecnica presenta requisiti non particolarmente stringenti:

- Il learner deve avere dimensioni tali da poter essere manovrato da un operatore senza interfacce esterne.
- Learner e teacher devono essere co-locati.
- Il teacher deve avere le abilità necessarie per manovrare abilmente il demonstrator.

3.1.3 Procedura

1. L'operatore manovra il robot, esplicitando inizio e fine della dimostrazione.
2. L'operatore riesegue il punto 1 un numero di volte tale per cui le inconsistenze e movimenti di una singola dimostrazione abbiano un effetto trascurabile sul risultato finale (talvolta sono presenti delle metriche per la valutazione della performance del teacher).
3. Vengono applicate delle tecniche di post-processing sui dati ottenuti dalle dimostrazioni, come i Gaussian Mixture Models (GMM) e tecniche di regressione, per attenuare il rumore e ricavare pattern comuni a tutte le dimostrazioni.

3.1.4 Vantaggi e Svantaggi

La tecnica presenta i seguenti vantaggi:

- Poiché la dimostrazione è effettuata direttamente manovrando il learner, non è presente il problema della corrispondenza, spiegato in sezione [2.4.1](#).
- I limiti di movimento del learner corrispondono ai suoi limiti intrinseci o a quelli dovuti all'ambiente in cui si trova.
- È una tecnica efficiente in termini di risorse, dato che sono necessarie strumentazioni ulteriori ai sensori interni già tipicamente presenti all'interno del learner, necessari per la registrazione della dimostrazione. Non è necessario inoltre sviluppare alcuna interfaccia software aggiuntiva.
- È una tecnica intuitiva per il teacher.

La tecnica presenta i seguenti svantaggi:

- La performance del learner è vincolata dalle capacità del teacher di eseguire il task efficientemente ed in modo fluido [\[1\]](#).
- È necessario insegnare al teacher come manovrare il learner, poiché, contrariamente a buona parte del lavoro presente in letteratura, in un contesto operativo reale le dimostrazioni non sono eseguite da esperti del settore.
- Manovrare il robot può risultare impossibile quando questo presenta un elevato grado di libertà di movimento. Per questa motivazione in letteratura la tecnica è utilizzata principalmente per learner con un semplice form factor.
- Il requisito di co-località è limitante per alcuni contesti estremi o inaccessibili, come quelli marini o spaziali.

3.1.5 Utilizzo in Letteratura

Il kinesthetic teaching è una delle tecniche di dimostrazione più utilizzate per via della sua semplicità [5]. In [6] viene utilizzato per insegnare ad un robot a stendere l'impasto di una pizza. In [7] un robot apprende come effettuare un nodo. In [8] viene esplorata la possibilità di utilizzare le dimostrazioni sbagliate dal teacher come esempio di cosa non fare. In [9] vengono discusse e valutate le metodologie per insegnare ai teacher come manovrare efficientemente i robot per migliorare l'apprendimento. Lo studio mostra che utilizzare video esplicativi risulta essere il metodo migliore, poiché i partecipanti tendono a non rispettare le istruzioni scritte fornite. In [10] viene proposto un metodo per la valutazione delle dimostrazioni eseguite dal teacher, mostrando come fornendo feedback a quest'ultimi le performance dei robot migliorano. In [11] e [12] viene presentata una variante dell'apprendimento cinestetico, nella quale le dimostrazioni corrispondono ad un insieme di punti sparsi nello spazio di stato che si vuole visitare in sequenza. In altre parole durante la dimostrazione il teacher mette in diverse pose il robot e ne memorizza lo stato e posizione in sequenza; questo permette di ovviare al rumore e a spostamenti involontari in fase di dimostrazione, permettendo inoltre una rappresentazione più compatta, essendo l'insieme di punti memorizzato più sparso. In letteratura ci si riferisce a questo tipo di dimostrazione come *Keyframe demonstration*, ed al metodo usuale come *Trajectory demonstration*. Tuttavia questa tecnica non permette di memorizzare informazioni riguardanti tempo e velocità. Per questo motivo le più classiche trajectory demonstration possono risultare più consone per curve particolarmente complesse, come presentato in [13]. Nello stesso lavoro viene presentato un framework che permette di lavorare con entrambi i tipi di dimostrazione per l'inferenza delle policy. In [14] l'apprendimento cinestetico e il reinforcement learning sono combinati per ottenere risultati significativi con un basso numero di dimostrazioni. Questo è possibile grazie al post-processing effettuato sui dati delle traiettorie ottenuti tramite le dimostrazioni.

3.2 Teleoperazione

3.2.1 Descrizione

La teleoperazione per la LfD consiste nell'effettuare le dimostrazioni manovrando il learner da remoto tramite interfacce di controllo come GUI, joystick, AR/VR e dispositivi aptici. I dati delle dimostrazioni sono quindi ottenuti tramite i sensori interni al learner sotto forma di serie temporali. Come l'apprendimento cinestetico si tratta di una tecnica in cui non è necessario effettuare l'embodiment mapping, rientrando quindi nella categoria delle dimostrazioni pure.

3.2.2 Requisiti

- Il learner deve poter essere manovrato tramite teleoperazione. Impedimenti potrebbero essere la difficoltà di riprodurre alcuni feedback tattili, come forza e coppia percepita.
- Risorse a sufficienza per lo sviluppo di un'interfaccia remota.
- Il teacher deve avere le abilità necessarie per manovrare il learner tramite l'interfaccia di controllo remota.

3.2.3 Procedura

1. Si sviluppa l'interfaccia di controllo remota per manovrare il learner.
2. Il teacher opera il learner tramite l'interfaccia di controllo, performando il task desiderato.
3. Il punto 2 viene eseguito un numero di volte tale per cui i dati raccolti risultino soddisfacenti ai fini di un addestramento per un'esecuzione autonoma.
4. Si applicano delle tecniche di generalizzazione sui dati acquisiti dalle dimostrazioni (in particolare le DMP[15]), per attenuare il rumore e ricavare pattern comuni.

3.2.4 Vantaggi e Svantaggi

La tecnica ha i seguenti vantaggi:

- Poichè la dimostrazione è effettuata direttamente manovrando il learner, non è presente il problema della corrispondenza, spiegato in sezione 2.4.1.
- Il controllo a distanza del learner consente di lavorare anche in ambienti estremi.
- Il controllo digitale permette di effettuare la procedura anche con ambiente e learner simulati.
- Possibilità di effettuare dimostrazioni su larga scala [16] [17].

La tecnica ha i seguenti svantaggi:

- Lo sviluppo di interfacce di teleoperazione può risultare complesso e dispendioso. Sono necessarie competenze trasversali, e la strumentazione necessaria può risultare difficilmente reperibile.

- L'utilizzo delle interfacce può risultare complesso per i teacher, ostacolando la facoltà di applicare la tecnica a non esperti del settore. Non trascurabile è inoltre l'affaticamento cognitivo dovuto all'uso prolungato di queste interfacce.
- Tradurre i movimenti del learner in un'interfaccia controllabile da un operatore può risultare estremamente complicato, specialmente se presenta un elevato grado di libertà di movimento.

3.2.5 Utilizzo in Letteratura

La teleoperazione è tra le tecniche più utilizzate nel campo della LfD, come dimostrato dal vasto ed eterogeneo utilizzo che se ne fa in letteratura. Si tratta di una tecnica a lungo studiata, come testimoniato da [18], paper del 2003 dove viene insegnato ad un robot umanoide della NASA, controllato da remoto tramite realtà virtuale, come effettuare operazioni semplici, come lo spostamento di oggetti. In [19] dei ROV (Remotely Operated Vehicle) sottomarini controllati tramite VR come operare, utilizzando la conoscenza per operare autonomamente solamente in caso di mancanza di comunicazione con l'operatore. Questa modalità di lavoro è comunemente denominata *hot stabbing*. Un'altra delle peculiarità fondamentali della teleoperazione è l'opportunità di utilizzare learner simulati. Questa possibilità è esplorata in [20], dove vengono allenati agenti virtuali a giocare autonomamente a *robosoccer* tramite la conoscenza di giocatori umani. L'utilizzo di ambienti ed agenti simulati permette di raccogliere dati tramite dimostrazioni in larga scala. Questo permette a più teacher di lavorare contemporaneamente, senza la necessità di manovrare fisicamente il learner fisico (non simulato). Diversi lavori in letteratura trattano la possibilità di utilizzare il crowdsourcing come forma di raccolta dati, grazie all'utilizzo della realtà virtuale, sfruttando ad esempio la comunità di videogiocatori [16] o attraverso questionari aperti [17]. In [21] viene insegnato a droni controllati tramite joystick come compiere manovre complesse grazie all'addestramento da parte di piloti esperti.

3.3 Shadowing

3.3.1 Descrizione

Lo shadowing è una tecnica di dimostrazione nella quale il learner osserva ed imita i movimenti del teacher. In questa fase vengono memorizzati i dati dei sensori interni al learner, da cui vengono poi ricavate le policy. Il learner può reagire ai movimenti inferiti dal teacher così da correggerli.

3.3.2 Requisiti

I requisiti per effettuare questa tecnica sono:

- Strumentazione necessaria all'osservazione dei movimenti del teacher.
- Risorse a sufficienza per lo sviluppo di algoritmi di riconoscimento e mapping delle azioni effettuate dal teacher.
- Hardware performante per l'esecuzione on-line degli algoritmi di riconoscimento e mapping.

3.3.3 Procedura

1. Sviluppo di una piattaforma per il riconoscimento dei movimenti del teacher.
2. Sviluppo di un algoritmo che mappi le azioni del teacher nell'insieme delle azioni del learner.
3. Esecuzione delle dimostrazioni e raccolta dei dati interni al learner.
4. Derivazione delle policy sulla base delle variazioni degli stati del learner.

3.3.4 Vantaggi e Svantaggi

La tecnica presenta i seguenti vantaggi:

- Il teacher non necessita l'apprendimento di piattaforme tecnologiche complesse. Per questa motivazione questa tecnica può risultare più semplice per i non esperti del settore.
- È possibile correggere in real-time i movimenti effettuati dal learner.

La tecnica presenta i seguenti svantaggi:

- La strumentazione necessaria al riconoscimento delle azioni del teacher può risultare costosa.
- Lo sviluppo di un algoritmo performante per il mapping dalle azioni del teacher a quelle del learner può risultare particolarmente oneroso, principalmente a causa della necessità che questo avvenga on-line.

3.3.5 Utilizzo in Letteratura

In [22] un operatore umano insegna ad un robot umanoide come spostare un oggetto da un punto ad un altro, muovendosi attraverso punti intermedi. Nello stesso elaborato

viene inoltre affrontato l'apprendimento utilizzando come teacher dei robot, effettuando un semplice task di movimento tramite punti intermedi. I risultati sono però meno validi, poiché i robot non presentano la stessa capacità di adattamento all'ambiente, tipica degli esseri umani, concludendosi in dimostrazioni peggiori. Nel paper non viene esplorata la possibilità di inferire nuove azioni, al contrario di [23], dove viene insegnato ad un robot come muovere le braccia imitando un operatore umano. In [24] viene insegnato ad un robot manipolatore come muoversi e maneggiare oggetti. Viene utilizzato un approccio master-slave, in cui il braccio destro del robot manipolatore viene controllato dal teacher, mentre il sinistro ne ripete i movimenti osservandolo.

3.4 Reactive Guidance

3.4.1 Descrizione

Questa tecnica si concentra sulla capacità del robot di reagire dinamicamente agli input dell'ambiente e di adattarsi rapidamente alle condizioni che cambiano, basandosi sull'interazione con l'operatore umano che fornisce le dimostrazioni.

3.4.2 Requisiti

La tecnica presenta i seguenti requisiti:

- Co-locazione del teacher e del learner.
- Teacher e robot devono poter interagire.
- Il robot deve reagire alle dimostrazioni in tempi accettabili.
- Il teacher deve avere le abilità necessarie per interagire correttamente con il learner tramite feedback.

3.4.3 Procedura

1. Il robot è in grado di realizzare delle azioni di base.
2. In base alla tecnica che si è deciso di utilizzare l'operatore dà un feedback al robot.
3. Il feedback derivante dall'interazione va a modificare l'esecuzione dell'azione.
4. Si itera il procedimento fino a quando il comportamento non è soddisfacente.

3.4.4 Vantaggi e Svantaggi

I vantaggi di utilizzare questa tecnica sono i seguenti:

- Permette di utilizzare diversi metodi per fornire il feedback, tra questi abbiamo RL (Reinforcement Learning), IRL (Inverse Reinforcement Learning), IRL-PBRS (Interactive Reinforcement Learning - Potential Based Reward Shaping), quindi si può trovare quella più adatta al caso che si sta considerando.
- Utilizzare il feedback ha il vantaggio di correggere il comportamento in tempo reale, inoltre l'apprendimento può essere più rapido ed efficiente dato che riceve informazioni su come migliorare il proprio comportamento. Con una conseguente riduzione della dimensione dello spazio di ricerca.
- L'operatore può utilizzare interfacce per correggere il comportamento del robot, non occorre dunque avere operatori con un grande livello di formazione.

Tuttavia è soggetto ai seguenti svantaggi:

- Prima di ottenere un comportamento che sia soddisfacente potrebbero occorrere numerose dimostrazioni, e in realtà aziendali è difficile che questo accada.
- Fornisce soluzioni sub-ottimali. Dato che il feedback è immediato mette in atto correzioni senza avere una visione globale del compito, che quindi potrebbero non essere ottimali per il compito successivo.
- Il sistema potrebbe adattarsi troppo al feedback fornito durante una dimostrazione specifica, senza riuscire a generalizzare il comportamento in nuovi contesti o varianti della dimostrazione.

3.4.5 Utilizzo in Letteratura

La Reactive Guidance in letteratura viene ampiamente utilizzata in combinazione con il Reinforcement Learning perché entrambi i metodi sono orientati al miglioramento progressivo del comportamento. Un'applicazione tipica è quella in cui si devono realizzare dei processi di assemblaggio, nel lavoro in [25] e [26] si evidenzia come l'utilizzo di tecniche IRL-PBRS (che si basa sul definire dei constrain al robot) riduce notevolmente il numero di interazioni necessarie ad ottenere un buon risultato. Un'altro utilizzo di questo approccio è quello per il tedioso compito di stima di parametri, come discusso in [27], il feedback dell'utente viene utilizzato per determinare un range praticabile di un determinato parametro in maniera veloce. Un'ultimo esempio è quello presente in [28], in cui si cerca di utilizzare il robot anche in applicazioni domestiche. Nello scenario proposto il robot riceve consigli vocali da un istruttore umano tramite riconoscimento vocale automatico, ed esegue un task di pulizia.

3.5 Sensors on Teacher

3.5.1 Descrizione

La tecnica Sensor on Teacher nella Learning from Demonstration (LfD) è un approccio in cui i sensori vengono montati direttamente sul teacher durante la dimostrazione di un compito. I sensori catturano dati dettagliati sui movimenti e sulle interazioni fisiche, che vengono poi utilizzati per addestrare un sistema o un robot a replicare l'azione dimostrata. Questa tecnica permette il trasferimento di conoscenza dall'umano al robot, è particolarmente utilizzata in quei casi in cui il task da imparare è molto complesso.

3.5.2 Requisiti

- È necessario disporre di risorse a sufficienza per lo sviluppo di un sistema di acquisizione adatto alla dimostrazione.
- È necessario disporre di risorse a sufficienza per lo sviluppo di un algoritmo di mapping tra teacher e demonstrator.

3.5.3 Procedura

1. Il dimostratore viene equipaggiato con dei sensori ed esegue le dimostrazioni
2. Si acquisiscono e condizionano i dati dai sensori.
3. I dati acquisiti vengono utilizzati per creare una rappresentazione digitale dei movimenti e delle azioni eseguite dal dimostratore.
4. Questi dati vengono utilizzati addestrare l'agente che sulla base delle informazioni raccolte cerca di replicare i movimenti.

3.5.4 Vantaggi e Svantaggi

I principali vantaggi di questa tecnica sono i seguenti:

- I dati raccolti sui movimenti e le forze applicate durante il compito sono estremamente accurati, questo permette una rappresentazione fedele delle azioni.
- Consente di raccogliere informazioni che non sarebbero facilmente osservabili a occhio nudo, come l'entità della forza applicata o la velocità esatta di un movimento.

I principali svantaggi della tecnica sono i seguenti:

- L'uso di sensori richiede una prima fase di configurazione che in generale è molto lunga, inoltre la loro presenza può essere scomoda per il demonstrator, interferendo con i movimenti naturali e alterando la fluidità della dimostrazione.
- I dati raccolti dalla dimostrazione potrebbero essere soggetti al rumore dovuto alla dimostrazione dell'utente.
- Il task appreso è molto specifico, quindi non si ha generalizzazione.
- I dati raccolti dal demonstrator vanno adattati a quelle che sono le proprietà del robot (problematica dell'embodiment di cui abbiamo già parlato in precedenza).
- Occorre definire una fase in cui si va a valutare l'esecuzione del task, che deve essere fatta su misura per testarne il comportamento

3.5.5 Utilizzo in Letteratura

Un lavoro che evidenzia la potenza di questo approccio è quello mostrato in [29], in cui il dispositivo wearable è un guanto equipaggiato con i sensori, che l'utente utilizza per eseguire il task. La realizzazione di questi dispositivi non è affatto banale; quella del guanto appena citato è descritta in questo articolo [30]. In questo lavoro si fa inoltre utilizzo di rete neurali per cercare di generalizzare le capacità del robot nel task che deve apprendere.

La tecnica ha portato ad attività di ricerca non solo sull'apprendimento dalla dimostrazione, ma anche sulla progettazione di reti sensoriali avanzate per l'acquisizione dei dati durante le dimostrazioni. Questo è fondamentale per garantire che i dati acquisiti siano di alta qualità e utilizzabili per il processo di apprendimento automatico, un esempio ne è il seguente lavoro [31].

3.6 External Observation

3.6.1 Descrizione

Il processo di dimostrazione viene monitorato e registrato tramite dispositivi esterni come telecamere, sensori di profondità, microfoni, o altri strumenti di rilevamento che catturano la scena in cui il dimostratore esegue un'attività. Questi strumenti permettono di ottenere una rappresentazione dettagliata del contesto, delle interazioni fisiche e delle azioni del dimostratore.

3.6.2 Requisiti

I requisiti per poter applicare questa tecnica sono:

- Avere a disposizione le risorse necessarie a realizzare un sistema percettivo in grado di osservare la dimostrazione.
- I dati che vengono raccolti, in base alla metodologia utilizzata vanno elaborati tramite tecniche di computer vision o machine learning.
- In alcune applicazioni, come l'assistenza sanitaria, è fondamentale garantire che i dati raccolti rispettino i protocolli di privacy e che le informazioni personali siano trattate in modo sicuro.

3.6.3 Procedura

1. Si sviluppa il sistema di percezione del robot.
2. Il teacher svolge la dimostrazione, questa può essere on-line oppure registrata.
3. A partire dalle acquisizioni si applicano gli algoritmi per far apprendere i task.

3.6.4 Vantaggi e Svantaggi

I principali vantaggi della tecnica sono:

- La natura del sistema di percezione consente di catturare informazioni su tutto l'ambiente circostante, non solo sul dimostratore. Questo aiuta a comprendere come le azioni del dimostratore interagiscono con gli oggetti e l'ambiente.
- Lo stesso setup di data acquisition può essere applicato a una varietà di scenari e compiti senza necessitare di modifiche sostanziali.

Mentre i principali svantaggi di questa tecnica sono:

- Per estrarre informazioni utili al learner i dati devono essere elaborati e interpretati, il che può richiedere algoritmi complessi e notevole potenza di calcolo.
- Sensori esterni potrebbero non essere sufficientemente precisi per catturare dettagli fini delle azioni o per distinguere tra movimenti simili.
- Sensori esterni potrebbero non essere sufficientemente precisi per catturare dettagli fini delle azioni o per distinguere tra movimenti simili.

3.6.5 Utilizzo in Letteratura

Nel paper [32] è stato realizzato un sistema visivo per monitorare la dimostrazione. Affinché il learner possa apprendere in maniera corretta occorre che questo si trovi

esattamente davanti al teacher, in letterature si parla di corrispondenza tra il learner e il corpo del demonstraor, detto anche **ego-image**. Per questo motivo ci sono numerosi articoli in cui si cerca di effettuare trasformazioni dei punti di vista [33], mentre in [34] si utilizzano i video delle dimostrazioni per dare al robot un'idea del contesto in cui si trova e fare così prediction sulle azioni che eseguirà il demonstrator.

Capitolo 4

Conclusioni

Come si può evincere dallo stato dell'arte esaminato in questo documento, la Learning from Demonstration risulta essere una tecnica eterogenea nelle sue modalità. La tecnologia ha raggiunto una maturità tale da permetterne l'utilizzo anche al di fuori dal contesto accademico. Tuttavia la sua diffusione è ancora limitata a causa degli investimenti necessari. I significativi progressi tecnologici nell'ambito della robotica e del machine learning permetteranno un'adozione sempre maggiore da parte della realtà aziendali. In questo contesto, la scelta delle tecniche di dimostrazione è critica, e in questo elaborato le abbiamo studiate da un punto di vista applicativo per fornire un riferimento su come effettuare questa decisione.

Bibliografia

- [1] Brenna D Argall et al. «A survey of robot learning from demonstration». In: *Robotics and autonomous systems* 57.5 (2009), pp. 469–483.
- [2] Arturo Daniel Sosa-Ceron, Hugo Gustavo Gonzalez-Hernandez e Jorge Antonio Reyes-Avendaño. «Learning from demonstrations in human–robot collaborative scenarios: A survey». In: *Robotics* 11.6 (2022), p. 126.
- [3] R.A. Peters et al. «Robonaut task learning through teleoperation». In: *2003 IEEE International Conference on Robotics and Automation (Cat. No.03CH37422)*. Vol. 2. 2003, 2806–2811 vol.2. DOI: [10.1109/ROBOT.2003.1242017](https://doi.org/10.1109/ROBOT.2003.1242017).
- [4] Weitian Wang et al. «Facilitating Human–Robot Collaborative Tasks by Teaching-Learning-Collaboration From Human Demonstrations». In: *IEEE Transactions on Automation Science and Engineering* 16.2 (2019), pp. 640–653. DOI: [10.1109/TASE.2018.2840345](https://doi.org/10.1109/TASE.2018.2840345).
- [5] Maram Sakr et al. «Training human teacher to improve robot learning from demonstration: A pilot study on kinesthetic teaching». In: *2020 29th IEEE International Conference on Robot and Human Interactive Communication (RO-MAN)*. IEEE. 2020, pp. 800–806.
- [6] Nadia Figueroa, Ana Lucia Pais Ureche e Aude Billard. «Learning complex sequential tasks from demonstration: A pizza dough rolling case study». In: *2016 11th ACM/IEEE International Conference on Human-Robot Interaction (HRI)*. Ieee. 2016, pp. 611–612.
- [7] John Schulman et al. «Learning from demonstrations through the use of non-rigid registration». In: *Robotics Research: The 16th International Symposium ISRR*. Springer. 2016, pp. 339–354.
- [8] Daniel H Grollman e Aude Billard. «Donut as i do: Learning from failed demonstrations». In: *2011 IEEE international conference on robotics and automation*. IEEE. 2011, pp. 3804–3809.
- [9] Maya Cakmak e Leila Takayama. «Teaching people how to teach robots: The effect of instructional materials and dialog design». In: *Proceedings of the 2014*

- ACM/IEEE international conference on Human-robot interaction*. 2014, pp. 431–438.
- [10] Aran Sena e Matthew Howard. «Quantifying teaching behavior in robot learning from demonstration». In: *The International Journal of Robotics Research* 39.1 (2020), pp. 54–72.
 - [11] Pieter Abbeel e Andrew Y Ng. «Apprenticeship learning via inverse reinforcement learning». In: *Proceedings of the twenty-first international conference on Machine learning*. 2004, p. 1.
 - [12] Baris Akgun et al. «Augmenting kinesthetic teaching with keyframes». In: *ICML workshop on new developments in imitation learning*. Citeseer. 2011.
 - [13] Baris Akgun et al. «Keyframe-based learning from demonstration: Method and evaluation». In: *International Journal of Social Robotics* 4 (2012), pp. 343–355.
 - [14] Cem Eteke, Doğançan Kebüde e Barış Akgün. «Reward learning from very few demonstrations». In: *IEEE Transactions on Robotics* 37.3 (2020), pp. 893–904.
 - [15] Auke Jan Ijspeert et al. «Dynamical movement primitives: learning attractor models for motor behaviors». In: *Neural computation* 25.2 (2013), pp. 328–373.
 - [16] David Whitney, Eric Rosen e Stefanie Tellex. «Learning from crowdsourced virtual reality demonstrations». In: *Proceedings of the 1st International Workshop on Virtual, Augmented, and Mixed Reality for HRI (VAM-HRI)*. 2018.
 - [17] Russell Toris, David Kent e Sonia Chernova. «Unsupervised learning of multi-hypothesized pick-and-place task templates via crowdsourcing». In: *2015 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE. 2015, pp. 4504–4510.
 - [18] Richard Alan Peters et al. «Robonaut task learning through teleoperation». In: *2003 IEEE International Conference on Robotics and Automation (Cat. No. 03CH37422)*. Vol. 2. IEEE. 2003, pp. 2806–2811.
 - [19] Ioannis Havoutis e Sylvain Calinon. «Learning from demonstration for semi-autonomous teleoperation». In: *Autonomous Robots* 43 (2019), pp. 713–726.
 - [20] Ricardo Aler, Oscar Garcia e José María Valls. «Correcting and improving imitation models of humans for robosoccer agents». In: *2005 IEEE Congress on Evolutionary Computation*. Vol. 3. IEEE. 2005, pp. 2402–2409.
 - [21] Pieter Abbeel, Adam Coates e Andrew Y Ng. «Autonomous helicopter aerobatics through apprenticeship learning». In: *The International Journal of Robotics Research* 29.13 (2010), pp. 1608–1639.
 - [22] Monica N Nicolescu e Maja J Mataric. «Experience-based representation construction: learning from human and robot teachers». In: *Proceedings 2001*

- IEEE/RSJ International Conference on Intelligent Robots and Systems. Expanding the Societal Role of Robotics in the the Next Millennium (Cat. No. 01CH37180)*. Vol. 2. IEEE. 2001, pp. 740–745.
- [23] Masaki Ogino et al. «Interaction rule learning with a human partner based on an imitation faculty with a simple visuo-motor mapping». In: *Robotics and Autonomous Systems* 54.5 (2006), pp. 414–418.
 - [24] Ning Wang, Chuize Chen e Alessandro Di Nuovo. «A framework of hybrid force/motion skills learning for robots». In: *IEEE Transactions on Cognitive and Developmental Systems* 13.1 (2020), pp. 162–170.
 - [25] Joris De Winter et al. «Accelerating Interactive Reinforcement Learning by Human Advice for an Assembly Task by a Cobot». In: *Robotics* 8.4 (2019). ISSN: 2218-6581. DOI: [10.3390/robotics8040104](https://doi.org/10.3390/robotics8040104). URL: <https://www.mdpi.com/2218-6581/8/4/104>.
 - [26] Aljaž Kramberger et al. «Learning of assembly constraints by demonstration and active exploration». In: *Industrial Robot: An International Journal* 43.5 (2016), pp. 524–534.
 - [27] Mattia Racca, Ville Kyrki e Maya Cakmak. «Interactive Tuning of Robot Program Parameters via Expected Divergence Maximization». In: *2020 15th ACM/IEEE International Conference on Human-Robot Interaction (HRI)*. 2020, pp. 629–638.
 - [28] Francisco Cruz et al. «Interactive reinforcement learning through speech guidance in a domestic scenario». In: *2015 International Joint Conference on Neural Networks (IJCNN)*. 2015, pp. 1–8. DOI: [10.1109/IJCNN.2015.7280477](https://doi.org/10.1109/IJCNN.2015.7280477).
 - [29] Rajmeet Singh et al. «Human–Robot Interaction Using Learning from Demonstrations and a Wearable Glove with Multiple Sensors». In: *Sensors* 23.24 (2023). ISSN: 1424-8220. DOI: [10.3390/s23249780](https://doi.org/10.3390/s23249780). URL: <https://www.mdpi.com/1424-8220/23/24/9780>.
 - [30] Fei Fei et al. «Development of a Wearable Glove System with Multiple Sensors for Hand Kinematics Assessment». In: *Micromachines* 12.4 (2021). ISSN: 2072-666X. DOI: [10.3390/mi12040362](https://doi.org/10.3390/mi12040362). URL: <https://www.mdpi.com/2072-666X/12/4/362>.
 - [31] Jie Li et al. «Real-Time Human Motion Capture Based on Wearable Inertial Sensor Networks». In: *IEEE Internet of Things Journal* 9.11 (2022), pp. 8953–8966. DOI: [10.1109/JIOT.2021.3119328](https://doi.org/10.1109/JIOT.2021.3119328).
 - [32] Rüdiger Dillmann, M Kaiser e Ales Ude. «Acquisition of elementary robot skills from human demonstration». In: *International symposium on intelligent robotics systems*. Citeseer. 1995, pp. 185–192.

- [33] M. Lopes e J. Santos-Victor. «Visual learning by imitation with motor representations». In: *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)* 35.3 (2005), pp. 438–449. DOI: [10.1109/TSMCB.2005.846654](https://doi.org/10.1109/TSMCB.2005.846654).
- [34] YuXuan Liu et al. «Imitation from Observation: Learning to Imitate Behaviors from Raw Video via Context Translation». In: *2018 IEEE International Conference on Robotics and Automation (ICRA)*. 2018, pp. 1118–1125. DOI: [10.1109/ICRA.2018.8462901](https://doi.org/10.1109/ICRA.2018.8462901).